UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE COMPUTAÇÃO
CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO

ANA VITÓRIA VAZ SANTOS - 12221BSI219
BERNARDO CARVALHO TRINDADE - 12321BSI253
JOEL SILVEIRA MARQUES PEREIRA - 12221BSI265

RELATÓRIO SOBRE AGRUPAMENTO DE MUNICÍPIOS PELA INCIDÊNCIA DE DOENÇAS

UBERLÂNDIA
2026

SUMÁRIO

1 INTRODUÇÃO 2

2 DESCRIÇÃO DOS DADOS E ANÁLISE EXPLORATÓRIA 3
2.1 Seleção e Refinamento de Atributos 3
2.2 Análise de Correlação 4

3 METODOLOGIA 7
3.1 Pré-processamento e Engenharia de Características 7
3.2 Agrupamento com K-Means e Avaliação de k 7
3.3 Agrupamento Baseado em Densidade com DBSCAN 8

4 RESULTADOS E DISCUSSÃO 9
4.1 Perfil Detalhado dos Clusters (K-Means) 9
4.2 Municípios de Alerta Máximo (Cluster 1) 9
4.3 Detecção e Investigação de Anomalias (DBSCAN) 10
4.4 Foco Regional: Análise das Capitais do Nordeste 11
4.5 Diagnóstico do Modelo (XAI): O que define o Risco Máximo? . . . 12

5 CONCLUSÕES 14

REFERÊNCIAS 15

1 INTRODUÇÃO

Este relatório técnico detalha o desenvolvimento do Projeto Final de Ciência de Dados II, que tem como premissa o agrupamento de municípios brasileiros com base em seus perfis epidemiológicos e socioeconômicos. A saúde pública no Brasil enfrenta desafios contínuos devido à vasta extensão territorial e à profunda desigualdade social, tornando essencial o mapeamento de áreas de risco para o direcionamento assertivo de políticas públicas.

Utilizando microdados abertos fornecidos pelo Sistema de Informação de Agravos de Notificação (SINAN) do DATASUS (DATASUS, 2026) e indicadores de desenvolvimento do PNUD (PNUD, 2010), o estudo busca identificar padrões de ocorrência simultânea de doenças negligenciadas e avaliar sua forte correlação com o Índice de Desenvolvimento Humano Municipal (IDHM). A análise atual foca especificamente na base de registros de Dengue (2025) como o agravo principal para realizar a segmentação e entender a dinâmica territorial da doença.

2 DESCRIÇÃO DOS DADOS E ANÁLISE EXPLORATÓRIA

A base de dados primária foi extraída do SINAN/DATASUS (DATASUS, 2026), totalizando inicialmente 1.655.637 registros e 121 atributos. Esses registros representam as notificações individuais de pacientes. Além disso, foram incorporados os dados do Atlas do Desenvolvimento Humano no Brasil (PNUD, 2010), que fornecem o IDHM, permitindo cruzar a saúde clínica com a realidade infraestrutural do município.

O projeto envolveu uma etapa rigorosa de limpeza de dados (*Data Cleaning*), convertendo códigos de preenchimento "Ignorado"(frequentemente representados pelo valor `9` nos sistemas do Ministério da Saúde) em valores nulos (`NaN`). Variáveis que apresentaram mais de 90% de ausência de dados em sua completude foram removidas da análise para evitar ruídos.

2.1 Seleção e Refinamento de Atributos

Diferente de abordagens mais generalistas, optamos por manter e priorizar atributos clínicos específicos (como Febre, Mialgia, Cefaleia) e indicadores socioeconômicos (Escolaridade, Raça/Cor). Essa escolha permite capturar a complexidade do perfil do paciente. Para assegurar a validade espacial, a base foi estritamente filtrada para manter apenas os casos classificados como autóctones (`TPAUTOCTO = 1`), garantindo que a infraestrutura socioeconômica (IDHM) corresponde diretamente ao local de infecção.

Figura 1 – Diagnóstico de Qualidade: Variáveis por % de ausência de dados

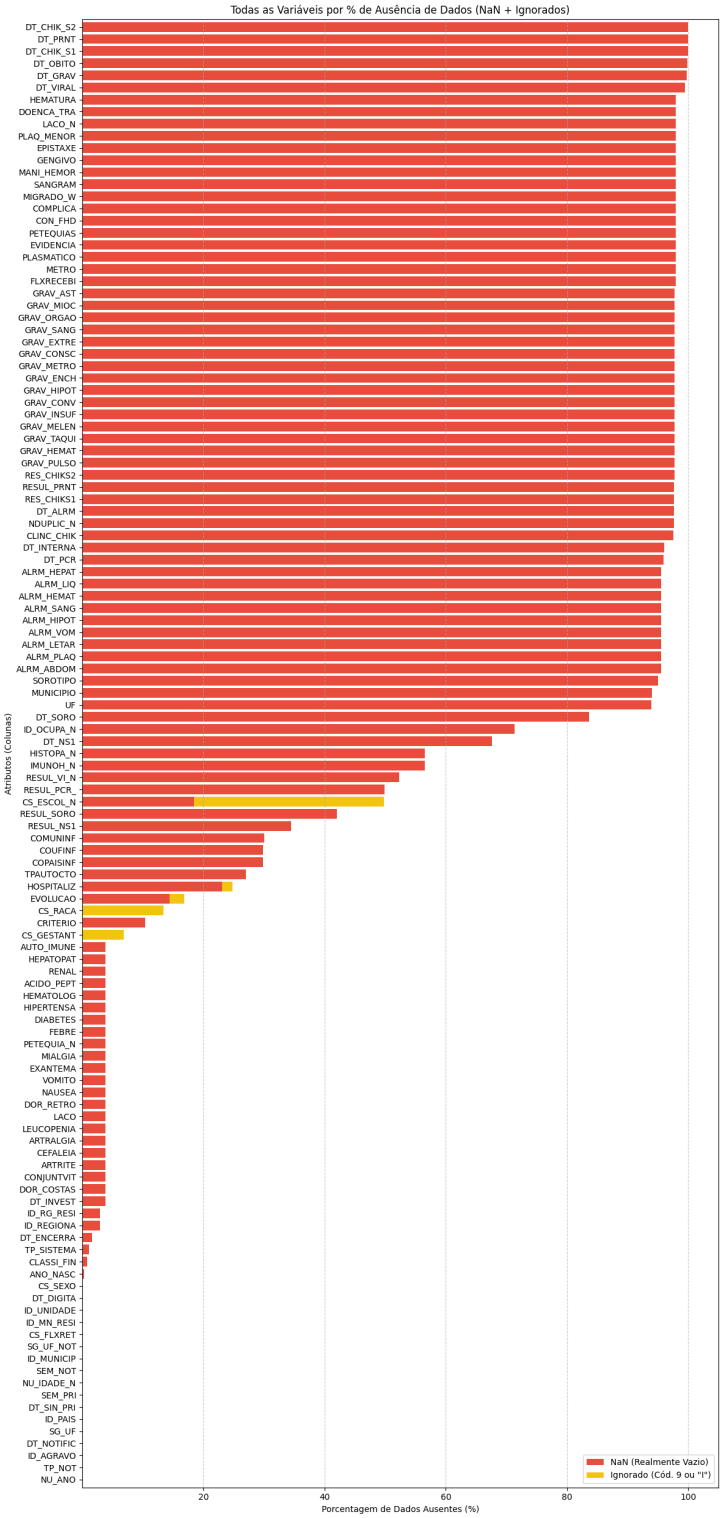

2.2 Análise de Correlação

Durante a Análise Exploratória de Dados (EDA), aplicamos a Matriz de Correlação de *Spearman* para identificar quais atributos epidemiológicos e socioeconômicos evoluem em conjunto, evitando redundâncias matemáticas antes da aplicação do Machine Learning.

Figura 2 – Matriz de Correlação (Spearman) - Atributos de Municípios

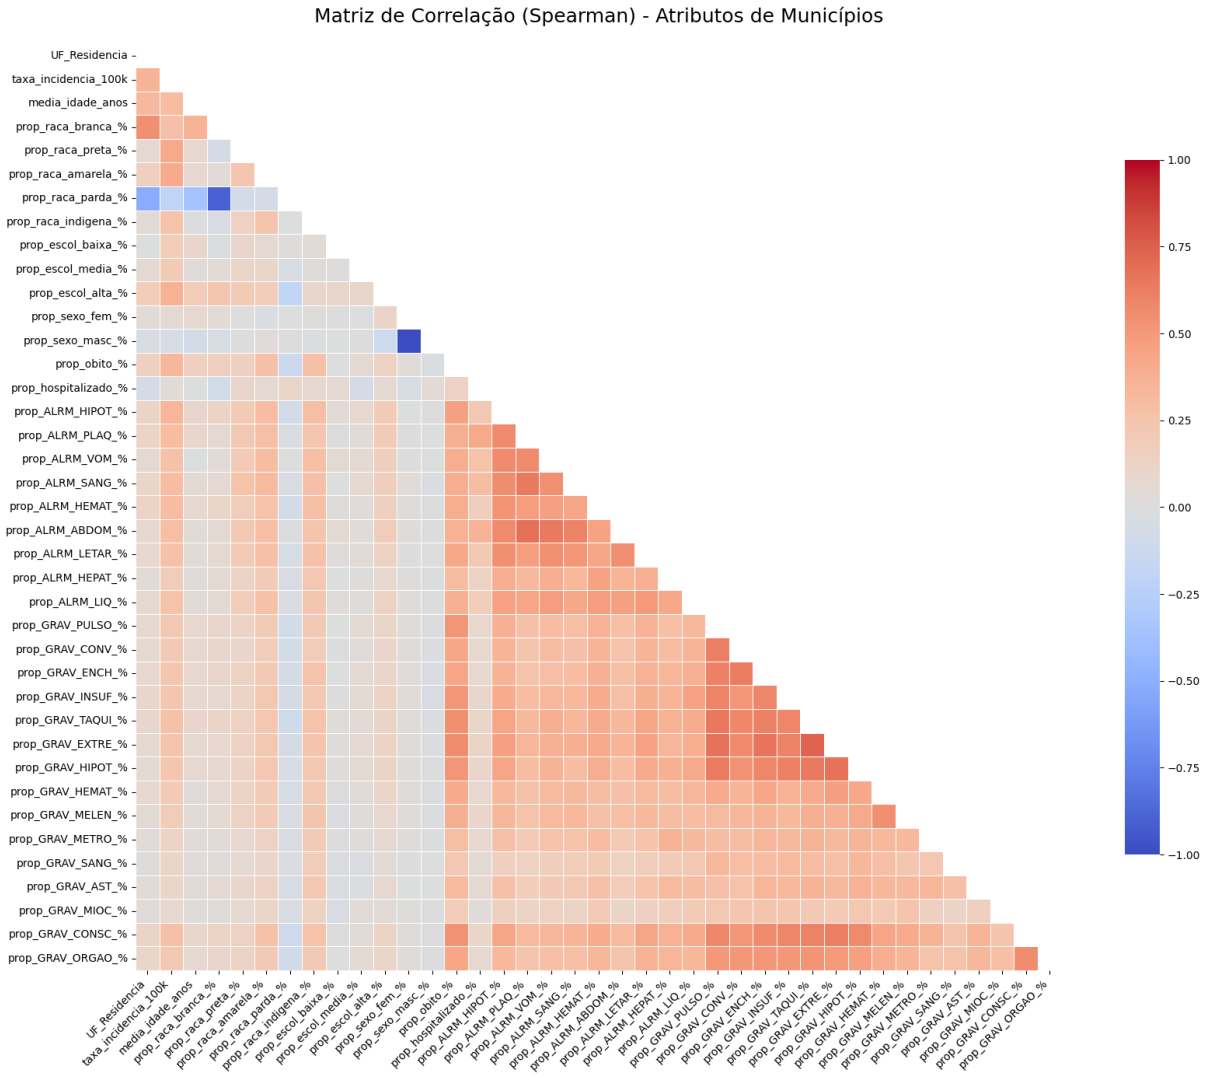

Figura 3 – Indices da matriz - Atributos de Municípios

```
============================================================
 EXTRAÇÃO DE INSIGHTS DA MATRIZ DE CORRELAÇÃO
============================================================

---> O QUE AUMENTA E DIMINUI A TAXA DE INCIDÊNCIA?

[+] Top 5 Fatores que Crescem JUNTO com a Incidência:
```

	taxa_incidencia_100k
prop_raca_preta_%	0.417
prop_raca_amarela_%	0.411
prop_escol_alta_%	0.372
UF_Residencia	0.365
prop_ALRM_HIPOT_%	0.348

```
[-] Top 5 Fatores que Caem quando a Incidência Sobe (Correlação Inversa):
```

	taxa_incidencia_100k
prop_GRAV_MIOC_%	0.084
prop_sexo_fem_%	0.049
prop_hospitalizado_%	0.033
prop_sexo_masc_%	-0.049
prop_raca_parda_%	-0.201

```
---> TOP 10 CORRELAÇÕES MAIS FORTES DO PROJETO (Risco de Redundância)
Se duas variáveis têm correlação acima de 0.80, elas dizem a mesma coisa.
```

	Variavel_1	Variavel_2	Correlacao
0	prop_sexo_fem_%	prop_sexo_masc_%	-1.000
1	prop_raca_branca_%	prop_raca_parda_%	-0.906
2	prop_GRAV_TAQUI_%	prop_GRAV_EXTRE_%	0.741
3	prop_ALRM_PLAQ_%	prop_ALRM_ABDOM_%	0.684
4	prop_GRAV_EXTRE_%	prop_GRAV_HIPOT_%	0.678
5	prop_GRAV_PULSO_%	prop_GRAV_EXTRE_%	0.675
6	prop_GRAV_ENCH_%	prop_GRAV_EXTRE_%	0.672
7	prop_GRAV_PULSO_%	prop_GRAV_TAQUI_%	0.654
8	prop_ALRM_PLAQ_%	prop_ALRM_SANG_%	0.648
9	prop_GRAV_TAQUI_%	prop_GRAV_HIPOT_%	0.645

```
============================================================
```

3 METODOLOGIA

A metodologia deste estudo evoluiu para uma análise comparativa e complementar entre algoritmos de agrupamento baseados em partição centroidal (K-Means) e baseados em densidade (DBScan), visando a extração do máximo de conhecimento intrínseco aos dados.

3.1 Pré-processamento e Engenharia de Características

Antes da aplicação dos modelos, os dados quantitativos foram estritamente normalizados via *StandardScaler*, mitigando o viés de variáveis com amplitudes diferentes. As incidências foram convertidas em taxas proporcionais (casos por 100 mil habitantes).

Um passo crucial nesta etapa foi o tratamento da inconsistência gerada pelo viés de pequenos números. Notou-se que os algoritmos estavam formando agrupamentos distorcidos baseados em cidades com pouquíssimos casos reportados. Por isso, como critério de corte estatístico, foram removidos da análise todos os municípios com menos de 10 casos registrados no ano, garantindo maior relevância aos clusters formados. Em seguida, os dados foram submetidos ao algoritmo de redução de dimensionalidade PCA (*Principal Component Analysis*) para permitir a visualização gráfica bidimensional (2D).

3.2 Agrupamento com K-Means e Avaliação de k

Para a aplicação do algoritmo K-Means, a definição do número ideal de clusters (k) foi embasada matematicamente. Utilizamos o **Método do Cotovelo (*Elbow Method*)** para analisar a inércia, aliado ao **Coeficiente de Silhueta (*Silhouette Score*)**, que validou a coesão interna e a separação externa, confirmando que a escolha de $k = 3$ agrupamentos oferecia a melhor representação.

Figura 4 – Gráficos do Método do Cotovelo e Coeficiente de Silhueta

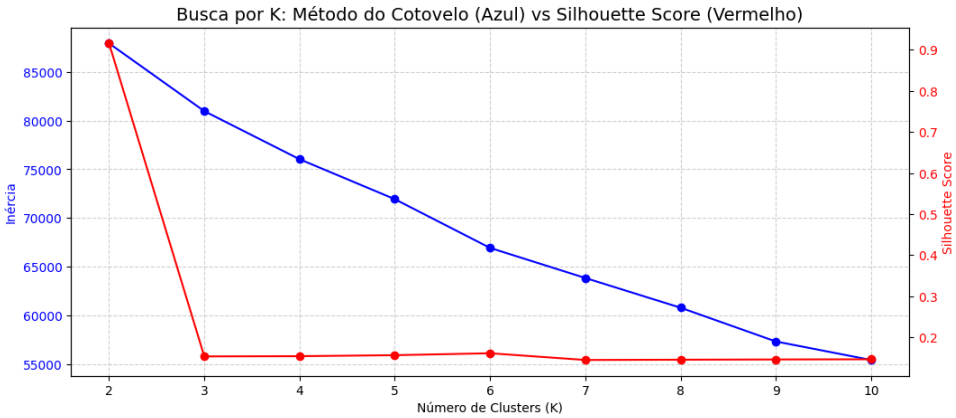

Figura 5 – Agrupamento K-Means ($k = 3$) projetado via PCA em 2D

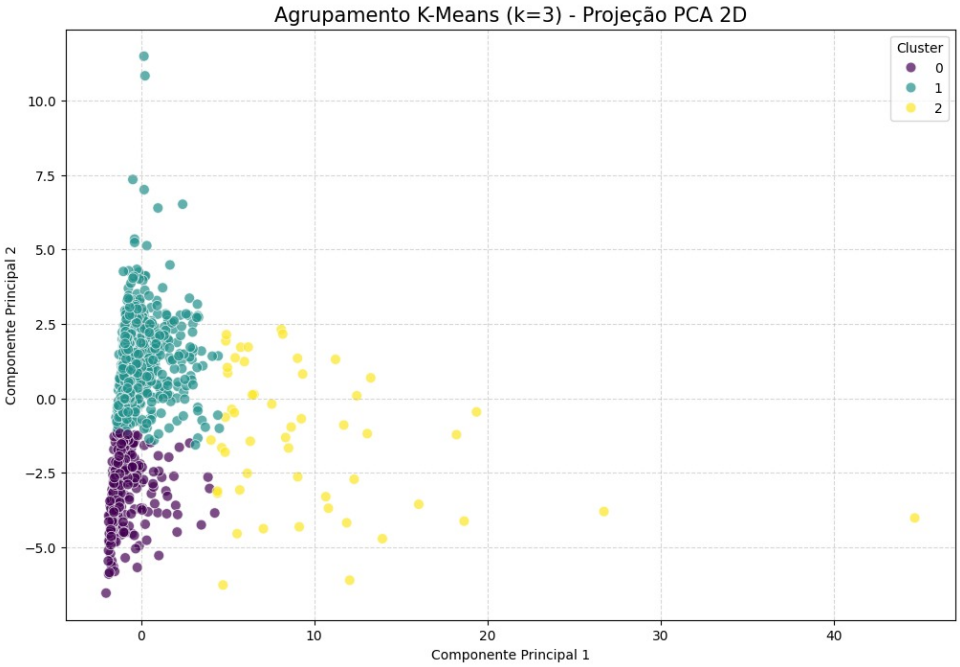

3.3 Agrupamento Baseado em Densidade com DBSCAN

Como contraponto, aplicamos o algoritmo **DBSCAN** (*Density-Based Spatial Clustering of Applications with Noise*). O K-Means tende a forçar a inclusão de pontos anômalos em clusters regulares. O DBSCAN foi escolhido estrategicamente pela sua habilidade de isolar *outliers* (ruídos), sendo de vital importância para as autoridades detectarem surtos anômalos ou falhas nos sistemas de notificação.

4 RESULTADOS E DISCUSSÃO

A análise revelou três perfis principais de municípios, com uma distinção marcante entre o comportamento endêmico padrão e cenários de alta vulnerabilidade clínica.

4.1 Perfil Detalhado dos Clusters (K-Means)

A Tabela 1 sumariza os centroides resultantes após a convergência do algoritmo. Para facilitar a interpretação, classificamos os clusters (0, 1 e 2) de acordo com suas características socioeconômicas e clínicas.

Tabela 1 – Resumo Estatístico e Perfil de Comportamento dos Clusters ($k = 3$)

Cluster	Perfil do Agrupamento	Qtd. Cidades	Incidência	IDHM	Óbito (%)	Hosp. (%)	Idade	Escol. Baixa
1	**Endêmico Padrão (Alerta Máximo)**	2047	660.5	0.675	0.23	12.56	34.9	22.96
2	**Alta Gravidade e Vulnerabilidade**	56	41.7	0.637	3.92	72.65	33.9	22.95
0	**Anomalia Crítica / Ruído**	2	7.9	0.706	50.00	100.00	41.0	50.00

Ao analisar a tabela, compreendemos perfeitamente a dinâmica da doença no país:

- O **Cluster 1** abriga a esmagadora maioria dos municípios. Este grupo é caracterizado por uma altíssima incidência da doença (660 casos por 100 mil/hab), porém com letalidade ínfima (0.23%) e baixa necessidade de internação. Representa o comportamento clássico de disseminação da Dengue em regiões endêmicas.
- O **Cluster 2** chama atenção por agrupar cidades com a menor média de IDHM (0.637). Apesar de possuírem incidência aparentemente mais baixa, apresentam uma taxa de hospitalização alarmante (72.65%) e mortalidade muito acima do padrão. Isso sinaliza fortemente que o baixo desenvolvimento humano está ligado a piores quadros clínicos e dificuldade de acesso rápido ao tratamento.
- O **Cluster 0** atua estritamente como um identificador de anomalias (ruído). Composto por apenas 2 municípios que registraram 100% de internação e 50% de letalidade, evidenciando uma claríssima subnotificação aguda (onde a cidade só registrou os pacientes que chegaram às UTIs) ou uma falha de sistema local.

4.2 Municípios de Alerta Máximo (Cluster 1)

Dentro do **Cluster 1**, as cidades que apresentam os maiores índices de incidência foram isoladas, conforme detalhado na Tabela. 2.

Tabela 2 – Top 15 Municípios com Piores Taxas no Cluster de Alerta Máximo

#	Município	UF	Incidência (100k)	Hosp. (%)	Índ. Sazon.	Mês do Pico
1	Porecatu	PR	18.263,94	4,76	0,38	02/2025
2	Conchas	SP	14.318,54	2,66	0,51	02/2025
3	Santa Cruz de M. Castelo	PR	13.479,62	2,76	0,48	03/2025
4	Atalaia	PR	11.356,78	2,21	0,46	03/2025
5	Alto Alegre	SP	11.247,07	17,13	0,47	03/2025
6	Bento de Abreu	SP	11.128,17	4,14	0,45	02/2025
7	Marilena	PR	10.933,41	11,98	0,39	02/2025
8	Mogi Mirim	SP	10.821,32	1,31	0,33	03/2025
9	Oscar Bressane	SP	10.242,91	3,16	0,36	03/2025
10	Palmital	SP	9.804,02	1,35	0,40	04/2025
11	Loanda	PR	9.709,36	0,93	0,48	02/2025
12	Turmalina	SP	9.706,41	3,70	0,55	01/2025
13	Morro Agudo	SP	8.978,63	3,47	0,33	02/2025
14	Gabriel Monteiro	SP	8.324,29	1,30	0,35	03/2025
15	Carneirinho	MG	8.172,36	0,91	0,41	03/2025

Nota: Total de municípios identificados neste perfil crítico: 841.

4.3 Detecção e Investigação de Anomalias (DBSCAN)

A execução do DBSCAN corroborou a presença das anomalias identificadas previamente pelo K-Means. Ao procurar regiões de extrema densidade e descartar pontos que não atingiam um limite mínimo de vizinhos estatísticos (*min_samples*), o algoritmo mapeou eficazmente os ruídos da amostra (pontos pretos na Figura 6).

Figura 6 – Dispersão dos agrupamentos formados e ruídos detectados pelo DBSCAN

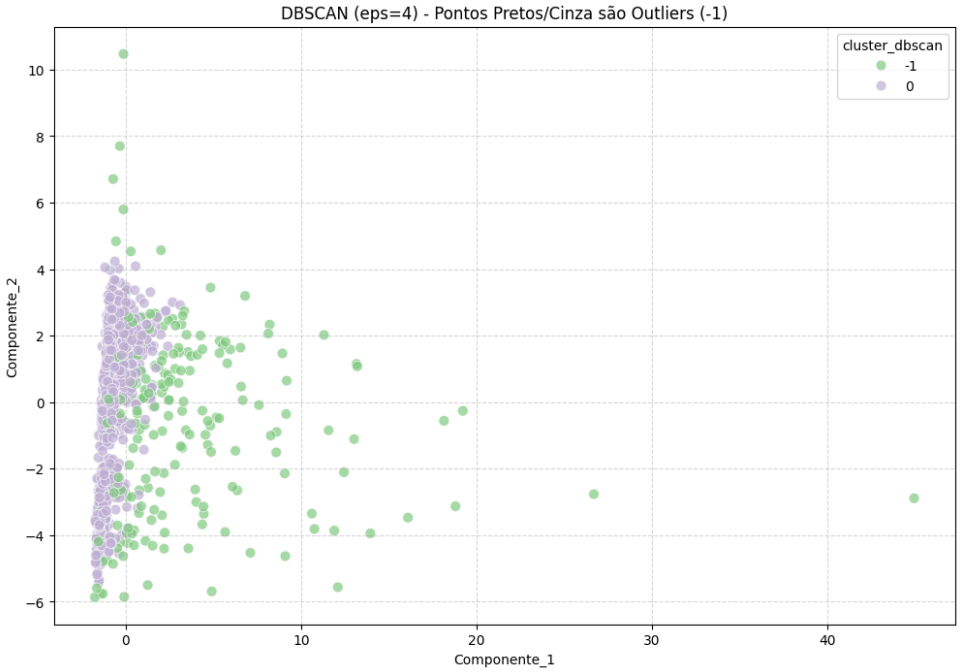

Para compreender a natureza desses ruídos com profundidade, realizamos uma

investigação do perfil dos municípios classificados como anomalias pelo algoritmo. A Figura 7 detalha o comportamento clínico dessas cidades, evidenciando que os *outliers* muitas vezes correspondem a localidades com taxas de letalidade absolutamente desproporcionais, problemas severos de subnotificação (apenas os casos de óbito ou UTI sendo registrados) ou falhas na alimentação do banco de dados municipal, o que justifica técnica e clinicamente sua exclusão dos clusters padrões.

Figura 7 – Investigação Analítica do Perfil dos Outliers (DBSCAN)

```
============================================================
 INVESTIGANDO OS 213 OUTLIERS (O QUE HÁ DE ESTRANHO NELES?)
============================================================
```

	Média Nacional	Média dos Outliers
taxa_incidencia_100k	1138.058423	899.414311
prop_hospitalizado_%	9.323768	21.499439
indice_sazonalidade_mensal	0.331880	0.332109

TOP 10 MUNICÍPIOS MAIS 'ANÔMALOS':

	nome_municipio	UF_Residencia	taxa_incidencia_100k	indice_sazonalidade_mensal
1656	Porecatu (PR)	41	18263.936683	0.361778
1249	Conchas (SP)	35	14318.539916	0.460895
1605	Laranjal (PR)	41	13000.000000	0.392236
1507	Turmalina (SP)	35	9706.411025	0.508571
1436	Pracinha (SP)	35	8650.116369	0.515695
1381	Onda Verde (SP)	35	7713.267659	0.274151
1440	Presidente Prudente (SP)	35	7422.408139	0.362106
1168	Alfredo Marcondes (SP)	35	5849.268841	0.461207
1300	Indaiatuba (SP)	35	5817.836308	0.441033
2070	Montividiu (GO)	52	5550.674866	0.239946

```
============================================================
```

4.4 Foco Regional: Análise das Capitais do Nordeste

Para complementar a visão nacional e compreender o impacto regionalizado da doença, realizamos um recorte analítico focado especificamente nas capitais da região Nordeste do Brasil. Devido ao longo histórico endêmico de arboviroses na região e às expressivas disparidades no índice de desenvolvimento intra e inter-metropolitano, este agrupamento permite observar como os grandes polos nordestinos se comportam frente à curva de contágio.

A Figura 8 sintetiza essa avaliação, ilustrando a distribuição das taxas de incidência e permitindo comparar diretamente o peso da doença nas principais concentrações demográficas do Nordeste.

Figura 8 – Análise Epidemiológica Focada nas Capitais do Nordeste

```
============================================================
ANÁLISE MACRO: AS 9 CAPITAIS DO NORDESTE (CORRIGIDA E BLINDADA)
============================================================
```

	Nome_Capital	taxa_incidencia_100k	prop_hospitalizado_%	indice_sazonalidade_mensal	Mês_do_Pico	cluster_kmeans
0	Teresina (PI)	334.53	9.52%	18.48%	2025-05	1
2	Natal (RN)	47.12	10.73%	14.66%	2025-08	1
4	Aracaju (SE)	22.07	18.80%	11.97%	2025-07	1
3	Recife (PE)	13.23	18.78%	17.28%	2025-08	1
5	Salvador (BA)	12.12	21.50%	12.57%	2025-05	1
1	Fortaleza (CE)	7.49	42.86%	12.93%	2025-07	1

```
[ANÁLISE ESTRATÉGICA - CAPITAIS DO NORDESTE]
O Índice de Sazonalidade agora está perfeitamente alinhado entre 0% e 100%.
============================================================
```

4.5 Diagnóstico do Modelo (XAI): O que define o Risco Máximo?

Para ir além da simples identificação descritiva dos agrupamentos, aplicou-se uma camada de Inteligência Artificial Explicável (XAI) através do algoritmo *Random Forest Classifier*. O objetivo principal foi isolar o agrupamento de Alerta Máximo (Cluster 1) e determinar quais variáveis atuaram, de fato, como os gatilhos matemáticos para classificar um município neste nível crítico de risco.

Visando garantir a integridade da análise, variáveis redundantes ou de correlação temporal absoluta (como contagem de meses com dengue, valores absolutos populacionais e identificadores de municípios) foram previamente removidas da base de treinamento (*Feature Selection*). Os resultados da importância de cada atributo (*Feature Importance*) extraídos do modelo revelaram a hierarquia dos fatores, conforme ilustrado na Figura 9.

Figura 9 – Quais fatores realmente definem uma cidade em Risco Máximo?

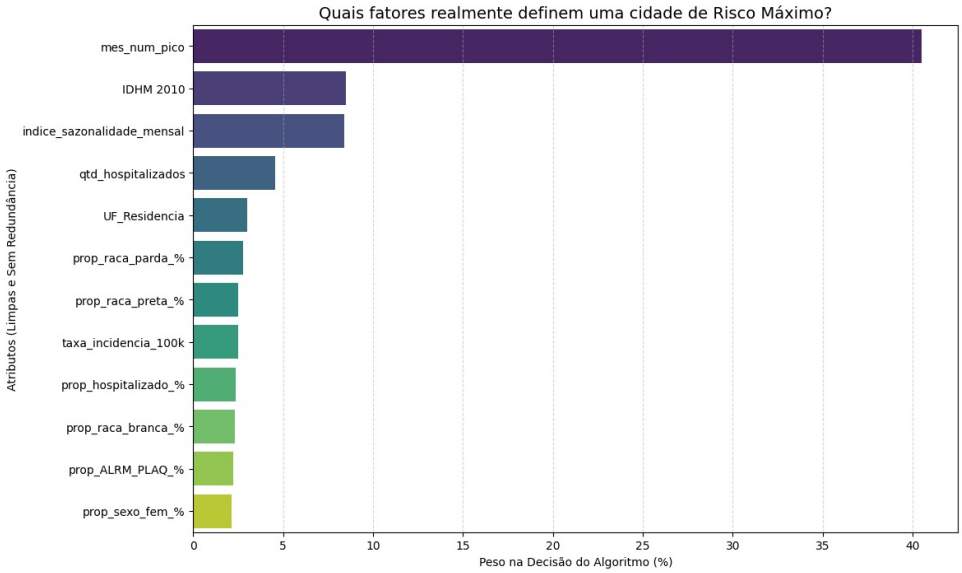

O diagnóstico do modelo destacou o seguinte peso percentual para os principais

fatores de risco: O diagnóstico do modelo destacou o seguinte peso percentual para os principais fatores de risco:

- **Mês do Pico Epidemiológico (`mes_num_pico` - 40,50%):** A explicação do modelo corrobora diretamente com a hipótese de que a questão climática (meses com maior precipitação e umidade) em dada região é bastante determinante para a incidência temporal da dengue. O fator temporal provou-se ser o elemento mais decisivo para o agrupamento, comprovando estatisticamente que a janela de maior proliferação do vetor está atrelada às chuvas sazonais específicas de cada estado.,Como mostrado na (Figura 8), onde selecionou-se cidades que sabidamente tem um clima tropical atlantico no qual as chuvas ocorrem predominantemente entre maio e agosto em contraponto com cidades do sudeste, que ocorrem no começo do ano como na (Figura 3)
- **Índice de Desenvolvimento Humano (`IDHM 2010` - 8,48%):** O IDHM figura como o segundo fator mais impactante do modelo, pois essa métrica é um reflexo direto da infraestrutura local. Municípios com menor desenvolvimento podem falhar na prevenção ideal contra os vetores ou até mesmo apresentar severa subnotificação de casos leves devido à falta de capacidade de atendimento nas unidades básicas de saúde. Esse fenômeno foi claramente demonstrado na análise regional das capitais nordestinas (Figura 8), onde cidades como Fortaleza apresentaram uma incidência relativamente baixa por 100 mil habitantes, mas registraram altíssimas taxas de internação, evidenciando que, por muitas vezes, é registrado no sistema local os pacientes que já chegam em estado grave.
- **Índice de Sazonalidade Mensal (8,41%):** Complementando o mês de pico, este índice reforça o peso da dimensão temporal, indicando que surtos muito concentrados de forma agressiva em um curto período são a marca registrada das cidades em risco máximo.

Nessa perspectiva, fica evidente que a classificação de um município como área em "Risco Máximo"não é uma casualidade regida apenas pelo volume populacional, mas sim o resultado direto do cruzamento de uma **janela de tempo climática crítica** (meses de chuva) com a **vulnerabilidade socioeconômica** local.

5 CONCLUSÕES

A integração sistêmica da preparação rigorosa de dados com técnicas de validação matemática (Método do Cotovelo e *Silhouette Score*) e algoritmos híbridos (K-Means e DBSCAN) permitiu uma segmentação epidemiológica robusta do território brasileiro.

O projeto conclui de forma empírica que a vulnerabilidade socioeconômica, traduzida por métricas como o IDHM (PNUD, 2010) e baixa escolaridade (características do Cluster 2), está intrínseca e diretamente ligada a piores desfechos clínicos (altas taxas de internação e óbito). Observou-se que municípios com baixo IDH, mesmo reportando menor volume de incidência absoluta no DATASUS (DATASUS, 2026), sofrem impactos proporcionalmente mais devastadores no sistema de saúde. Adicionalmente, a análise de explicabilidade (XAI) provou que a sazonalidade (meses de pico) da doença corresponde a 40% da definição de risco de uma área.

Tais descobertas ressaltam a urgência de políticas de prevenção públicas que sejam dinâmicas no tempo e que foquem prioritariamente na infraestrutura e no amparo social das regiões de menor índice de desenvolvimento, mitigando os efeitos antes mesmo da chegada do pico sazonal.

REFERÊNCIAS

DATASUS. *Departamento de Informática do Sistema Único de Saúde*. 2026. Acessado em: 01 mar. 2026. Disponível em: <https://datasus.saude.gov.br/>. Citado 3 vezes nas páginas 2, 3 e 14.

PNUD. *Atlas do Desenvolvimento Humano no Brasil*. 2010. Acessado em: 01 mar. 2026. Disponível em: <http://www.atlasbrasil.org.br/>. Citado 3 vezes nas páginas 2, 3 e 14.